

*Présentation de ...*

*One-bit Compressed Sensing by Linear Programming*

Yaniv Plan & Roman Vershynin (CPAM, 2013)

---

Théodor Lemerle & Théophile Cantelobre

Master M2A – Sorbonne Université

11 mars 2021

Motivation

Garanties théoriques


Expériences

Résumé & Conclusion

# Motivation


---

# Motivation : traitement du signal & CS idéal



- CS permet de reconstruire complètement le signal à partir de mesures... sans atteindre la fréquence de Nyquist-Shannon.
- Hypothèse :  $f(t) \in \mathbb{R}$ ... précision infinie !

# Motivation : traitement du signal & CS avec quantization



- Quantization comme bruit : CS permet de le corriger !
- Deux approches pour traiter le bruit de discrétisation : même nombre de bits !
  - Augmenter le nombre de bits par mesure : hardware lent.
  - Augmenter le nombre de mesures : hardware rapide.

# Quantization extrême : 1-bit compressed sensing

Poussé à l'extrême : **mesures avec 1-bit** (signes).

**Perte de l'amplitude**

$$\forall \lambda > 0, \text{sign}(A\lambda x) = \text{sign}(Ax)$$

**Problème de dégénérescence ( $\mathcal{BP}$ )**

$$\min_{x \in \mathbb{R}^n} \|x\|_1 \tag{1}$$

$$\text{s.t. } \text{sign}(Ax) = y \tag{2}$$

...decrease objective by multiplying admissible iterate by  $\lambda \rightarrow 0^+$ .

# Garanties théoriques

---

# Principal résultat

## Theorem (Théorème 1.1)

Soient  $n$ ,  $m$ , et  $s > 0$ . Soit  $A$  une **matrice gaussienne** de taille  $m \times n$ . Soit  $\delta > 0$  dépendant de  $s$ ,  $m$  et  $n$ . Alors, avec une probabilité au moins  $1 - C \exp(-c\delta m)$ , on a **uniformément** sur tout  $x \in \mathbb{R}^n$  qui sont **essentiellement parcimonieux** d'ordre  $s$  : si  $y = \text{sign}(Ax)$ . Alors, la solution  $\hat{x}$  du problème  $(\mathcal{P}_{1-\text{bit}})$  vérifie :

$$\left\| \frac{\hat{x}}{\|\hat{x}\|_2} - \frac{x}{\|x\|_2} \right\|_2 \leq \delta.$$

## Situation par rapport au cours

Points communs	Différences
Garanties uniformes.	Essentiellement parcimonieux.
Matrice de mesure gaussienne.	Reconstruction <i>inexacte</i> .



# Remarque : essentiellement parcimonieux


## Essentiellement parcimonieux

$$ES(x) = \frac{\|x\|_1^2}{\|x\|_2^2} \leq s$$

## Expérience numérique

Pour des vecteurs  $s$ -parcimonieux aléatoires,  $ES(x)$  estime bien  $\|x\|_0$  :

$$0.6s \lesssim ES(x) \lesssim 0.75s$$



## 1. Géométrie de la reconstruction à partir du signe.

**Outils principaux :** random tessellations &  $\varepsilon$ -nets.

**Résultat objectif :** pour  $m$  bien choisi, w.h.p. si  $\text{sign}(Ax) = \text{sign}(Ax')$  alors  $\|x - x'\|_2 \leq \delta$ .

## 2. Vecteurs essentiellement parcimonieux

**Outils principaux :** concentration de la mesure.

**Résultat objectif :** Une solution de notre problème d'optimisation préserve la parcimonie essentielle du signal d'intérêt :

$$ES(\hat{x}) \leq ES(x) \cdot C \sqrt{\log(2n/m + 2m/n)}$$

→ **Mise en commun**

$\hat{x}$  vérifie 2, donc 1 tient pour  $x$  et  $\hat{x}$  en particulier.

# Esquisse de la preuve : partie 1/2

## Idée générale

Quantifier combien de mesures gaussiennes de 1-bit il faut pour séparer tous les signaux possibles :

**avec h.p. uniformément sur les  $x, y$ , si  $\|x - y\|_2 > \delta$ , il existe  $\Omega(m)$  hyperplans qui séparent  $x$  et  $y$ .**

## 1. Contrôles des têtes et des queues

1. Séparer  $x$  (et  $y$ ) en :  $x = \underbrace{x_0}_{\in \text{net}} + \varepsilon x'$ .
2. S'assurer que les  $x_0$  et  $y_0$  sont séparés par  $\Omega(m)$  hyperplans.
3. S'assurer que les  $x'$  et  $y'$  le sont par  $\Omega(m) - o(m)$  hyperplans.
4. Tout mettre ensemble.

## 2. Plus petit $\varepsilon$ -net possible.

$$\log N(K_{n,s}, \varepsilon) \leq \frac{Cs}{\varepsilon^2} \log \left( \frac{2n}{s} \right)$$

## Esquisse de la preuve : partie 2/2

On veut montrer :  $\frac{\|\hat{x}\|_2^2}{\|\hat{x}\|_1^2} \leq \frac{\|x\|_2^2}{\|x\|_1^2} \cdot C \sqrt{\log(2n/m + 2m/n)}$

**Un résultat de concentration uniforme sur la déviation moyenne.**

$$\frac{1}{m} \|Ax\|_1 \geq \frac{\|x\|_2}{2} \text{ avec proba. au moins } 1 - C \exp(-cm)$$

La preuve reprend les grandes idées de la preuve de la propriété RIP pour les matrices à entrées gaussiennes.

**Une borne inférieure sur  $\|\hat{x}\|_2$**

$$\|\hat{x}\|_2 \geq c / \sqrt{\log(2n/m + 2m/n)}$$

Mis bout à bout :

$$\frac{\|\hat{x}\|_1}{\|\hat{x}\|_2} \leq \frac{\|x\|_1}{\|Ax\|_1 \|\hat{x}\|_2} \leq \frac{2 \|x\|_1}{\|\hat{x}\|_2 \|x\|_2} \leq \frac{\|x\|_2^2}{\|x\|_1^2} \cdot C \sqrt{\log(2n/m + 2m/n)}$$

## Résumé : un programme linéaire (LP) à résoudre

$$\min_{x \in \mathbb{R}^n} \|x\|_1$$

$$\text{s.t. } \text{sign}(Ax) = y$$

$$\|Ax\|_1 \geq m$$

## Résumé : un programme linéaire (LP) à résoudre

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \|x\|_1 \\ \text{s.t.} \quad & \text{sign}(Ax) = y \\ & \|Ax\|_1 \geq m \end{aligned}$$

$$\begin{aligned} \min_{u \in \mathbb{R}^n} \quad & \mathbf{1}^T u \\ \text{s.t.} \quad & \forall i, -u_i \leq y_i \leq u_i \\ & \forall i, u_i \geq 0 \\ & \forall i, y_i \langle A_i, x \rangle = 1 \\ & \langle y, Ax \rangle \geq m \end{aligned}$$

# Expériences

---

## Protocole expérimental

1. Générer un signal parcimonieux (dans une certaine base) :  $x$ .
2. Tirer une matrice  $A \sim \mathcal{N}(0, 1)$ .
3. Observer  $y = \text{sign}(Ax)$ .
4. Résoudre ( $\mathcal{P}_{1-bit}$ ) :  $\hat{x}$ .

... répéter  $N_{\text{trials}}$  fois.



## Protocole expérimental

1. Générer un signal parcimonieux (dans une certaine base) :  $x$ .
2. Tirer une matrice  $A \sim \mathcal{N}(0, 1)$ .
3. Observer  $y = \text{sign}(Ax)$ .
4. Résoudre ( $\mathcal{P}_{1-bit}$ ) :  $\hat{x}$ .

... répéter  $N_{\text{trials}}$  fois.

## Métriques : comment évaluer une reconstruction ? voir [18]

- Erreur angulaire :  $\epsilon(x, \hat{x}) = \frac{1}{\pi} \arccos \langle x, \hat{x} \rangle$
- Signal-to-Noise ratio :  $\text{SNR}(x, \hat{x}) = 20 \log_{10} \frac{\|x\|_2}{\|x - \hat{x}\|_2}$
- (Distance de Hamming :  $d_H(y, \hat{y}) = \frac{1}{m} \sum_{i=1}^m \text{XOR}(\text{sign}(Ay), \text{sign}(A\hat{y}))$ )

## Basis pursuit (avec seuillage)

Programmation linéaire puis seuillage :



$$\begin{aligned} \min_{x \in \mathbb{R}^n} \|x\|_1 \\ \text{s.t. } Ax = y \end{aligned}$$

## Binary Iterative Hard Thresholding [18]



Descente de gradient projetée (pour  $\|\cdot\|_0 = \text{Hard Thresholding}$ ) :

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \frac{1}{2} \|y - Ax\|_2^2 \\ \text{s.t. } \|x\|_0 = s \end{aligned}$$

# Reconstruction de signaux parcimonieux synthétiques (1/2)




## Reconstruction de signaux parcimonieux synthétiques (2/2)




Performance moyenne (10 essais) avec écart type.

À gauche : SNR. À droite : erreur angulaire. En abscisse :  $m/n$ .


Original




1-bit LP



BIHT



Basis Pursuit



## Résumé & Conclusion

---

## 1-bit compressed sensing with LP

- Reconstruction approximative du signal d'intérêt sur  $\mathbb{S}^{n-1}$ .
- Garanties uniformes sur les signaux essentiellement parcimonieux ( $\Sigma_s \subset K_{n,s}$ ).
- Programme linéaire.

## CS indissociable du mode d'acquisition

- Problématique hardware : vitesse d'échantillonnage vs qualité.
- Voir aussi choix du BOS, tomographie, ...

Des questions ?



- [0] : *One-bit Compressed Sensing by Linear Programming*, Plan & Vershynin (2013)
- [6] : *1-bit compressive sensing*, Boufounous & Baraniuk (2008)
- [18] : *Robust 1-bit compressive sensing via binary stable embeddings of sparse embeddings*, Jacques et al. (2011)